Informe de pruebas

Proyecto: Agrupamiento de estaciones de TransMilenio (Bogotá) por perfil de demanda **Curso:** Inteligencia Artificial, Corporación Universitaria Iberoamericana **Actividad:** 4 - Métodos de aprendizaje no supervisado

1. Objetivo

Verificar que el generador de datos y el agrupamiento se comportan como se documenta, y reportar con evidencia real los resultados del modelo no supervisado. Todas las salidas de este informe se obtuvieron ejecutando el código del repositorio con semilla 42.

2. Entorno

Elemento	Valor
Sistema operativo	macOS (Darwin)
Python	3.14.7
pytest	9.1.1
Bibliotecas	pandas, scikit-learn, matplotlib, pytest (`requirements.txt`)

3. Resultados de `python -m pytest -v`

Total: 12 pruebas, 12 aprobadas, 0 fallidas (2.29 s).

```
$ .venv/bin/python -m pytest -v
tests/test_cluster.py::test_features_have_no_nan_and_expected_width PASSED [  8%]
tests/test_cluster.py::test_hourly_shares_sum_to_one PASSED              [ 16%]
tests/test_cluster.py::test_choose_k_returns_k_in_range PASSED           [ 25%]
tests/test_cluster.py::test_choose_k_selects_four_archetypes PASSED      [ 33%]
tests/test_cluster.py::test_kmeans_beats_random_labels_on_silhouette PASSED [ 41%]
tests/test_cluster.py::test_kmeans_recovers_hidden_archetypes PASSED     [ 50%]
tests/test_cluster.py::test_hierarchical_agrees_with_kmeans PASSED       [ 58%]
tests/test_dataset.py::test_shape_and_columns PASSED                     [ 66%]
tests/test_dataset.py::test_no_nulls_and_valid_values PASSED             [ 75%]
tests/test_dataset.py::test_all_network_stations_have_an_archetype PASSED [ 83%]
tests/test_dataset.py::test_seed_reproducibility PASSED                  [ 91%]
tests/test_dataset.py::test_archetype_is_not_leaked_into_the_data PASSED [100%]

============================== 12 passed in 2.29s ==============================
```

Qué verifica cada prueba

Módulo	Prueba	Qué verifica
`test_dataset.py`	`test_shape_and_columns`	1200 filas (20 estaciones × 60 días) y columnas exactas: `station`, `day_type`, `rain`, `h05`..`h22`

Módulo	Prueba	Qué verifica
	`test_no_nulls_and_valid_values`	Sin nulos; `day_type` y `rain` con valores válidos; conteos no negativos y enteros
	`test_all_network_stations_have_an_archetype`	Cada estación de `network.json` tiene arquetipo asignado y viceversa
	`test_seed_reproducibility`	La misma semilla produce un DataFrame idéntico; una semilla distinta, datos distintos
	`test_archetype_is_not_leaked_into_the_data`	El arquetipo oculto no aparece como columna del CSV
`test_cluster.py`	`test_features_have_no_nan_and_expected_width`	La matriz de variables no tiene NaN y tiene 19 columnas (18 proporciones + volumen)
	`test_hourly_shares_sum_to_one`	Las proporciones horarias de cada fila suman 1
	`test_choose_k_returns_k_in_range`	`choose_k` devuelve un k del rango 2..8 con la mayor silueta
	`test_choose_k_selects_four_archetypes`	Con el conjunto por defecto, la silueta elige k = 4, igual al número de arquetipos del generador
	`test_kmeans_beats_random_labels_on_silhouette`	La silueta de KMeans supera en más de 0.1 a la de etiquetas aleatorias
	`test_kmeans_recovers_hidden_archetypes`	El índice de Rand ajustado contra el arquetipo oculto es mayor que 0.6
	`test_hierarchical_agrees_with_kmeans`	El agrupamiento jerárquico (Ward) coincide con KMeans (ARI mayor que 0.6)

Las pruebas usan las funciones reales, sin simulaciones (mocks).

4. Resultados de `python -m src.dataset`

```
$ .venv/bin/python -m src.dataset
Wrote 1200 rows x 21 columns to data/station_profiles.csv
day_type
weekday           0.614
saturday          0.194
sunday_holiday    0.192
rain share: 0.246
count    1200.0
mean     2037.0
std      1395.0
min       367.0
25%      1131.5
50%      1790.5
75%      2238.8
max      8038.0
```

5. Resultados de `python -m src.cluster`

Salida real:

```
$ .venv/bin/python -m src.cluster
Rows: 1200 | features: 19
Silhouette by k (KMeans):
  k=2: 0.496
  k=3: 0.608
  k=4: 0.618  <- chosen
  k=5: 0.465
  k=6: 0.416
  k=7: 0.269
  k=8: 0.268

ARI KMeans vs hierarchical:        1.000
ARI KMeans vs hidden archetype:    1.000  (validation only)
ARI hierarchical vs archetype:     1.000  (validation only)

Cluster 0: 360 station-days | mean total 1679
  day types: {'weekday': 0.59, 'saturday': 0.21, 'sunday_holiday': 0.19}
  top stations: {'Portal Eldorado': 60, 'Modelia': 60, 'Normandía': 60, 'Portal Américas': 60,
'Banderas': 60}

Cluster 1: 240 station-days | mean total 963
  day types: {'weekday': 0.64, 'sunday_holiday': 0.18, 'saturday': 0.18}
  top stations: {'Av. Rojas': 60, 'Corferias': 60, 'Concejo de Bogotá': 60, 'Puente Aranda': 60}

Cluster 2: 420 station-days | mean total 1789
  day types: {'weekday': 0.64, 'saturday': 0.19, 'sunday_holiday': 0.17}
  top stations: {'Calle 100': 60, 'Héroes': 60, 'Calle 72': 60, 'Calle 63': 60, 'Calle 45': 60}

Cluster 3: 180 station-days | mean total 4763
  day types: {'weekday': 0.56, 'sunday_holiday': 0.26, 'saturday': 0.18}
  top stations: {'Calle 26': 60, 'Centro Memoria': 60, 'Ricaurte': 60}

Plots saved to docs/img
```

6. Interpretación de los resultados

6.1 Elección de k

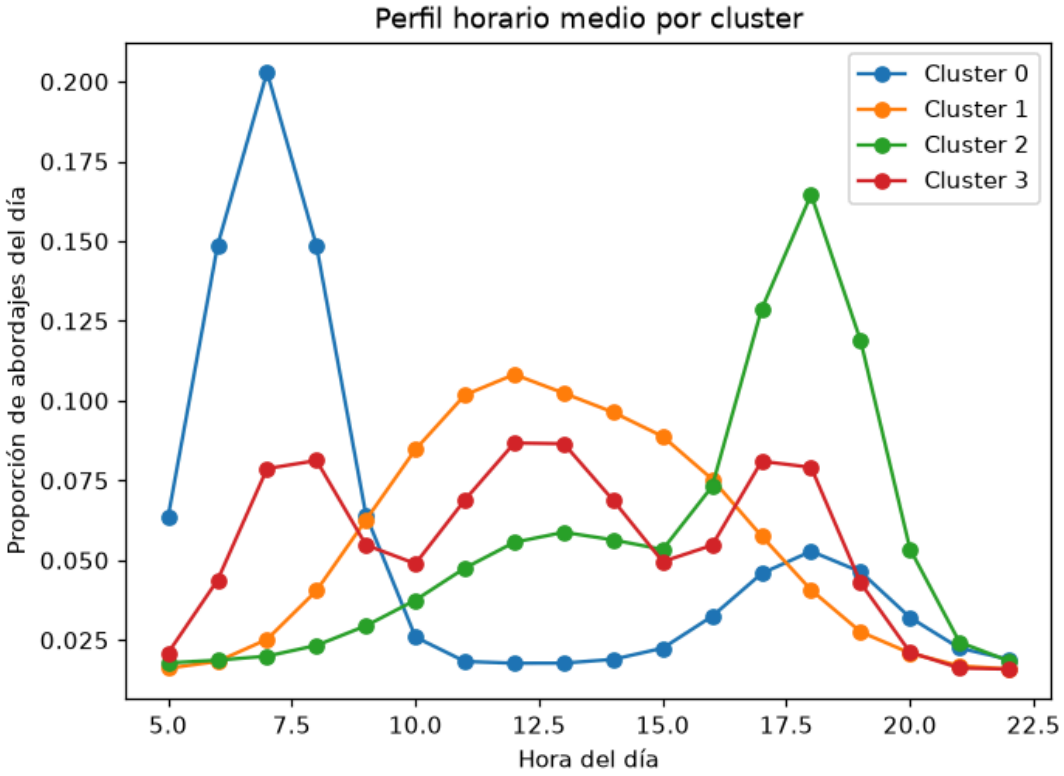
k	Silueta (KMeans)
2	0.496
3	0.608
4	**0.618**
5	0.465
6	0.416
7	0.269
8	0.268

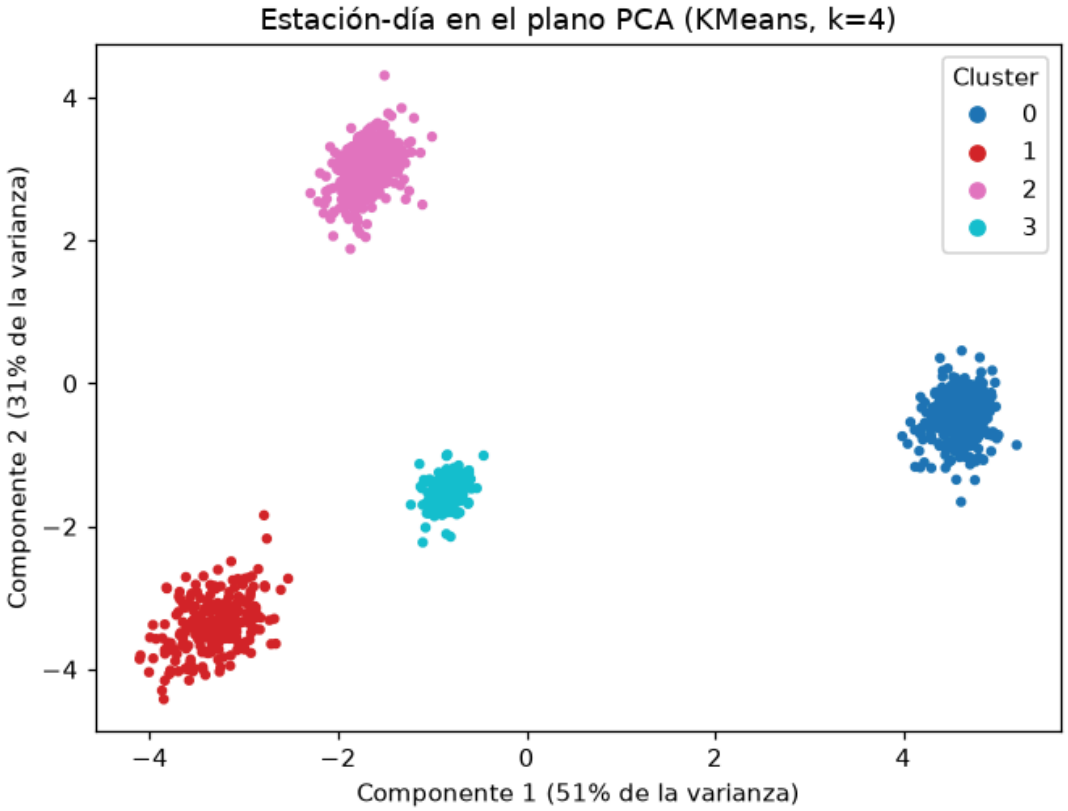
La silueta máxima está en k = 4 (0.618), igual al número de arquetipos del generador. Un valor cercano a 1 indica grupos compactos y bien separados; por encima de 0.6 se considera una estructura clara. La diferencia con k = 3 (0.608) es pequeña, de modo que k = 3 y k = 4 son casi equivalentes según el criterio; a partir de k = 5 la silueta cae con fuerza, señal de que se está partiendo grupos que ya eran compactos.

6.2 Grupos encontrados

Cluster	Estación-días	Volumen diario medio	Perfil horario	Estaciones
0	360	1679	Pico marcado en la mañana (7 h, cerca del 20 % de los abordajes del día)	Portal Eldorado, Portal Américas, Banderas, Marsella, Modelia, Normandía
1	240	963	Un solo abultamiento amplio entre media mañana y la tarde (máximo a las 12 h, cerca del 11 %), sin picos de hora pico	Av. Rojas, Corferias, Concejo de Bogotá, Puente Aranda
2	420	1789	Pico marcado en la tarde (18 h, cerca del 16 % de los abordajes) y meseta al mediodía	Calle 100, Calle 72, Calle 63, Calle 45, Calle 34, Héroes, Calle 75
3	180	4763	Tres picos: ambas horas pico (8 h y 18 h, cerca del 8 % cada una) y el mediodía (12-13 h, cerca del 9 %); el volumen es el más alto	Calle 26, Centro Memoria, Ricaurte

Lectura: el cluster 0 corresponde a estaciones de origen residencial (los pasajeros salen en la mañana), el cluster 2 a estaciones de destino laboral (los pasajeros regresan en la tarde), el cluster 3 a nodos de transbordo (volumen alto y repartido en tres picos) y el cluster 1 a estaciones mixtas de volumen bajo. La proporción de tipos de día es parecida en los cuatro grupos (día hábil entre 0.56 y 0.64; con solo 3 a 7 estaciones por grupo, esas diferencias son variación de muestreo), lo que indica que el agrupamiento separa tipos de estación y no tipos de día.





El plano PCA explica 51 % y 31 % de la varianza (83 % en total). Los cuatro clusters forman nubes compactas y separadas.

6.3 Validación externa

Comparación	ARI
KMeans frente a jerárquico (Ward)	1.000
KMeans frente a arquetipo oculto	1.000
Jerárquico frente a arquetipo oculto	1.000

El arquetipo oculto **no se usa para ajustar** los modelos; solo se compara al final. Los dos algoritmos producen la misma partición (ARI 1.000) y esa partición coincide exactamente con los arquetipos del generador.

6.4 Separación de `hub` y `mixed`

En la primera versión del generador, `hub` y `mixed` tenían casi la misma forma horaria (plana, con picos suaves) y se distinguían solo por el volumen. La silueta elegía k = 3 (0.640) y los fusionaba, con un ARI de 0.859 frente al arquetipo. Para separarlos se ajustaron los supuestos del generador en `src/dataset.py` (no el algoritmo de agrupamiento ni los umbrales de las pruebas): `hub` pasó a tener tres picos (ambas horas pico y el mediodía), `mixed` pasó a un único abultamiento amplio sin picos de hora pico, y el volumen base de `mixed` subió de 60 a 70. La tabla cruzada entre el arquetipo oculto y el cluster asignado por KMeans es ahora:

Arquetipo	Cluster 0	Cluster 1	Cluster 2	Cluster 3
`residential`	360	0	0	0
`business`	0	0	420	0
`hub`	0	0	0	180
`mixed`	0	240	0	0

Esta separación se logró **ajustando nuestros propios supuestos sintéticos**. Por eso el resultado demuestra que el método recupera grupos bien diferenciados, no que las estaciones reales de TransMilenio se comporten así.

7. Limitaciones

- **Datos sintéticos.** Los grupos son los arquetipos escritos en `src/dataset.py` más ruido. El resultado ilustra el método, no es una afirmación sobre el comportamiento real de TransMilenio.
- **Separación a medida.** El ARI de 1.000 se obtuvo después de diseñar las formas horarias de `hub` y `mixed` para que fueran distinguibles (sección 6.4); con datos reales, grupos con perfiles parecidos podrían fusionarse.
- **Una sola configuración.** Los resultados corresponden a una semilla (42) y a 60 días por estación; con otra semilla se esperan diferencias pequeñas en las siluetas.
- **Validación externa disponible solo por ser sintéticos.** Con datos reales no existiría un arquetipo de referencia y solo se podría usar la silueta y la interpretación de los perfiles.

8. Reproducibilidad

Toda la aleatoriedad usa la semilla 42 (`SEED` en `src/dataset.py` y `src/cluster.py`). Ejecutar de nuevo `python -m src.dataset` y `python -m src.cluster` produce el mismo archivo y las mismas métricas. Las instrucciones están en `docs/INSTRUCCIONES.md`.