Informe de pruebas

Proyecto: Agrupamiento de estaciones de TransMilenio (Bogotá) por perfil de demanda **Curso:** Inteligencia Artificial, Corporación Universitaria Iberoamericana **Actividad:** 4 - Métodos de aprendizaje no supervisado

1. Objetivo

Verificar que el generador de datos y el agrupamiento se comportan como se documenta, y reportar con evidencia real los resultados del modelo no supervisado. Todas las salidas de este informe se obtuvieron ejecutando el código del repositorio con semilla 42.

2. Entorno

Elemento	Valor
Sistema operativo	macOS (Darwin)
Python	3.14.7
pytest	9.1.1
Bibliotecas	pandas, scikit-learn, matplotlib, pytest (`requirements.txt`)

3. Resultados de `python -m pytest -v`

Total: 11 pruebas, 11 aprobadas, 0 fallidas (2.29 s).

```
$ .venv/bin/python -m pytest -v
tests/test_cluster.py::test_features_have_no_nan_and_expected_width PASSED [  9%]
tests/test_cluster.py::test_hourly_shares_sum_to_one PASSED              [ 18%]
tests/test_cluster.py::test_choose_k_returns_k_in_range PASSED           [ 27%]
tests/test_cluster.py::test_kmeans_beats_random_labels_on_silhouette PASSED [ 36%]
tests/test_cluster.py::test_kmeans_recovers_hidden_archetypes PASSED     [ 45%]
tests/test_cluster.py::test_hierarchical_agrees_with_kmeans PASSED       [ 54%]
tests/test_dataset.py::test_shape_and_columns PASSED                     [ 63%]
tests/test_dataset.py::test_no_nulls_and_valid_values PASSED             [ 72%]
tests/test_dataset.py::test_all_network_stations_have_an_archetype PASSED [ 81%]
tests/test_dataset.py::test_seed_reproducibility PASSED                  [ 90%]
tests/test_dataset.py::test_archetype_is_not_leaked_into_the_data PASSED [100%]

============================== 11 passed in 2.29s ==============================
```

Qué verifica cada prueba

Módulo	Prueba	Qué verifica
`test_dataset.py`	`test_shape_and_columns`	1200 filas (20 estaciones × 60 días) y columnas exactas: `station`, `day_type`, `rain`, `h05`..`h22`

Módulo	Prueba	Qué verifica
	`test_no_nulls_and_valid_values`	Sin nulos; `day_type` y `rain` con valores válidos; conteos no negativos y enteros
	`test_all_network_stations_have_an_archetype`	Cada estación de `network.json` tiene arquetipo asignado y viceversa
	`test_seed_reproducibility`	La misma semilla produce un DataFrame idéntico; una semilla distinta, datos distintos
	`test_archetype_is_not_leaked_into_the_data`	El arquetipo oculto no aparece como columna del CSV
`test_cluster.py`	`test_features_have_no_nan_and_expected_width`	La matriz de variables no tiene NaN y tiene 19 columnas (18 proporciones + volumen)
	`test_hourly_shares_sum_to_one`	Las proporciones horarias de cada fila suman 1
	`test_choose_k_returns_k_in_range`	`choose_k` devuelve un k del rango 2..8 con la mayor silueta
	`test_kmeans_beats_random_labels_on_silhouette`	La silueta de KMeans supera en más de 0.1 a la de etiquetas aleatorias
	`test_kmeans_recovers_hidden_archetypes`	El índice de Rand ajustado contra el arquetipo oculto es mayor que 0.6
	`test_hierarchical_agrees_with_kmeans`	El agrupamiento jerárquico (Ward) coincide con KMeans (ARI mayor que 0.6)

Las pruebas usan las funciones reales, sin simulaciones (mocks).

4. Resultados de `python -m src.dataset`

```
$ .venv/bin/python -m src.dataset
Wrote 1200 rows x 21 columns to data/station_profiles.csv
day_type
weekday           0.601
saturday          0.208
sunday_holiday    0.191
rain share: 0.243
count    1200.0
mean     2010.8
std      1403.4
min       342.0
25%      1055.5
50%      1777.5
75%      2237.2
max      7874.0
```

5. Resultados de `python -m src.cluster`

Salida real:

```
$ .venv/bin/python -m src.cluster
Rows: 1200 | features: 19
Silhouette by k (KMeans):
  k=2: 0.562
  k=3: 0.640  <- chosen
  k=4: 0.607
  k=5: 0.569
  k=6: 0.397
  k=7: 0.236
  k=8: 0.232

ARI KMeans vs hierarchical:        1.000
ARI KMeans vs hidden archetype:    0.859  (validation only)
ARI hierarchical vs archetype:     0.859  (validation only)

Cluster 0: 360 station-days | mean total 1687
  day types: {'weekday': 0.59, 'saturday': 0.22, 'sunday_holiday': 0.19}
  top stations: {'Portal Eldorado': 60, 'Modelia': 60, 'Normandía': 60, 'Portal Américas': 60,
'Banderas': 60}

Cluster 1: 420 station-days | mean total 2532
  day types: {'weekday': 0.59, 'saturday': 0.21, 'sunday_holiday': 0.2}
  top stations: {'Calle 26': 60, 'Av. Rojas': 60, 'Corferias': 60, 'Concejo de Bogotá': 60,
'Centro Memoria': 60}

Cluster 2: 420 station-days | mean total 1766
  day types: {'weekday': 0.62, 'saturday': 0.2, 'sunday_holiday': 0.18}
  top stations: {'Calle 100': 60, 'Héroes': 60, 'Calle 72': 60, 'Calle 63': 60, 'Calle 45': 60}

Plots saved to docs/img
```

6. Interpretación de los resultados

6.1 Elección de k

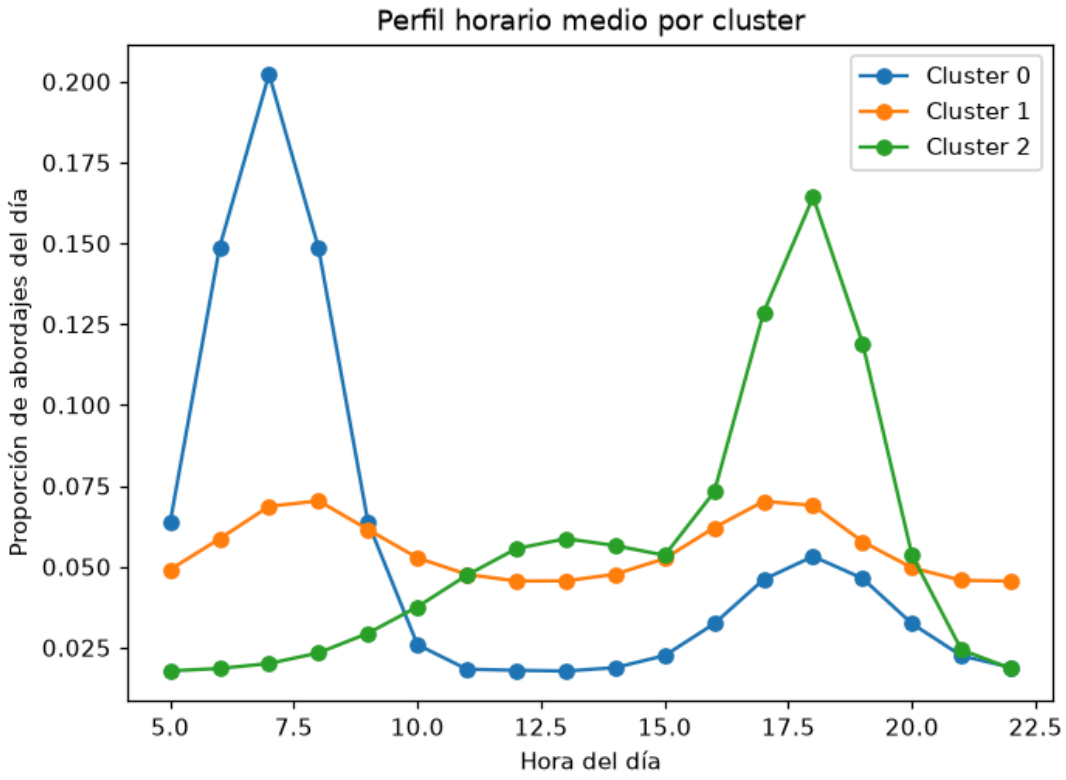
k	Silueta (KMeans)
2	0.562
3	**0.640**
4	0.607
5	0.569
6	0.397
7	0.236
8	0.232

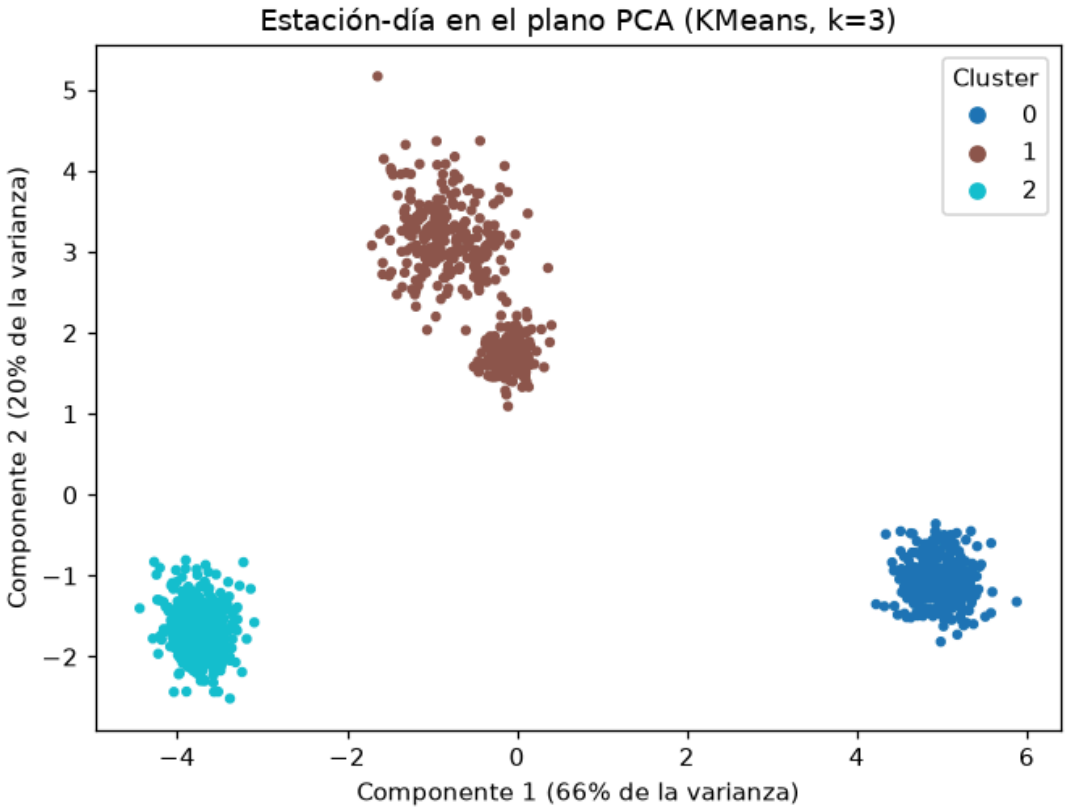
La silueta máxima está en k = 3 (0.640). Un valor cercano a 1 indica grupos compactos y bien separados; por encima de 0.6 se considera una estructura clara. A partir de k = 6 la silueta cae con fuerza, señal de que se está partiendo grupos que ya eran compactos.

6.2 Grupos encontrados

Cluster	Estación-días	Volumen diario medio	Perfil horario	Estaciones
0	360	1687	Pico marcado en la mañana (7 h, cerca del 20 % de los abordajes del día)	Portal Eldorado, Portal Américas, Banderas, Marsella, Modelia, Normandía
1	420	2532	Perfil plano con picos suaves en la mañana (8 h) y la tarde (17-18 h)	Calle 26, Centro Memoria, Ricaurte, Av. Rojas, Corferias, Concejo de Bogotá, Puente Aranda
2	420	1766	Pico marcado en la tarde (18 h, cerca del 16 % de los abordajes) y meseta al mediodía	Calle 100, Calle 72, Calle 63, Calle 45, Calle 34, Héroes, Calle 75

Lectura: el cluster 0 corresponde a estaciones de origen residencial (los pasajeros salen en la mañana), el cluster 2 a estaciones de destino laboral (los pasajeros regresan en la tarde) y el cluster 1 a estaciones con demanda repartida durante el día. La proporción de tipos de día es parecida en los tres grupos (aproximadamente 60 % día hábil, 20 % sábado, 20 % domingo o festivo), lo que confirma que el agrupamiento separa tipos de estación y no tipos de día.





El plano PCA explica 66 % y 20 % de la varianza (86 % en total). Los clusters 0 y 2 forman nubes compactas y bien separadas; el cluster 1 muestra dos subnubes visibles, que corresponden a los arquetipos `hub` y `mixed` (ver sección 6.4).

6.3 Validación externa

Comparación	ARI
KMeans frente a jerárquico (Ward)	1.000
KMeans frente a arquetipo oculto	0.859
Jerárquico frente a arquetipo oculto	0.859

El arquetipo oculto **no se usa para ajustar** los modelos; solo se compara al final. Los dos algoritmos producen la misma partición (ARI 1.000), lo que indica que la estructura de los datos es robusta frente al método de agrupamiento.

6.4 Hallazgo: `hub` y `mixed` quedan fusionados

El generador define cuatro arquetipos, pero el criterio de silueta elige k = 3. La tabla cruzada entre el arquetipo oculto y el cluster asignado por KMeans es:

Arquetipo	Cluster 0	Cluster 1	Cluster 2
`residential`	360	0	0
`business`	0	0	420
`hub`	0	180	0

Arquetipo	Cluster 0	Cluster 1	Cluster 2
mixed	0	240	0

hub (3 estaciones, 180 filas) y mixed (4 estaciones, 240 filas) caen juntos en el cluster 1. Tienen casi la misma forma horaria (plana, con picos suaves) y se distinguen sobre todo por el volumen. Por eso el ARI frente al arquetipo es 0.859 y no 1.0: no hay estaciones mal asignadas, sino dos arquetipos tratados como uno.

La silueta con k = 4 (0.607) es cercana a la de k = 3 (0.640), y el plano PCA ya muestra las dos subnubes. Es decir, el resultado k = 3 es una elección válida según el criterio, pero no agota la estructura de los datos. Una fase posterior revisa el generador para separar ambos arquetipos.

7. Limitaciones

- **Datos sintéticos.** Los grupos son los arquetipos escritos en src/dataset.py más ruido. El resultado ilustra el método, no es una afirmación sobre el comportamiento real de TransMilenio.
- **Fusión de hub y mixed.** El criterio de silueta elige k = 3 y agrupa dos arquetipos con forma parecida (sección 6.4).
- **Una sola configuración.** Los resultados corresponden a una semilla (42) y a 60 días por estación; con otra semilla se esperan diferencias pequeñas en las siluetas.
- **Validación externa disponible solo por ser sintéticos.** Con datos reales no existiría un arquetipo de referencia y solo se podría usar la silueta y la interpretación de los perfiles.

8. Reproducibilidad

Toda la aleatoriedad usa la semilla 42 (SEED en src/dataset.py y src/cluster.py). Ejecutar de nuevo python -m src.dataset y python -m src.cluster produce el mismo archivo y las mismas métricas. Las instrucciones están en docs/INSTRUCCIONES.md.